LLM API 价格：复现与扩展

快照：2026-03-31 | UW IS 451 课程小组项目的课后个人扩展

研究问题与数据

哪些可观察的模型特征与付费 API 价格相关？固定 Kaggle 版本 1：453 行中，138 行价格缺失、16 行价格为零，留下 299 行正价格样本。价格单位为每百万 token 的美元混合价格；provider 列实际代表模型开发者。

原结果复现

加回发布年份，沿用完整模型中 $p<0.05$ 的一次性筛选，自然得到 13 个解释项。精简模型 $R^2=0.574544$，调整 $R^2=0.555137$，与报告的 0.575、0.555 相符；不含年份的 notebook 版 $R^2=0.566571$。连续变量按 1 个标准差换算后的主要系数也对上报告。

诊断与样本外检验

原模型含只有一行样本的开发者，杠杆值等于 1，HC3 无法可靠计算。扩展部分将训练样本少于 5 行的开发者合并，再做 HC3 与 5 折分组验证，共 198 个基础模型组。缺失值填补、变量筛选及价格回转修正均只使用训练折。

样本外误差（美元单位均为每百万 token）

模型	log MAE	美元 MAE	美元 RMSE	样本外 log R^2
完整扩展	0.902	3.800	16.394	0.409
一次筛选	0.927	3.601	16.054	0.371
训练均值基准	1.236	4.443	16.417	-0.007

发现与业务含义

完整扩展模型样本内 $R^2=0.567$，样本外降至 0.409。筛选模型在美元误差上略低，但 log 误差更高；大额价格误差仍接近简单基准，不能把拟合价格当作可靠采购预算。

价格偏离候选

主排名覆盖 160 行：开发者在训练集出现、所有输入无需填补，且无已知年份错误。Gemma 3n E4B Instruct、Nova Lite 等低于预测基准；o3-pro 等高于基准。它们只是后续任务测试的候选信号，不代表质量优劣、公允价值或因果效果。

关键局限

只有一个历史快照。参数量缺失 103 行、年份缺失 84 行；有 5 行已知年份错配，历史复现保留原值。p 值筛选属探索性分析；分组依赖名称规则，且仅做一次固定分折。价格规律不能证明某模型适合特定任务。Kaggle 无更新快照，未做两期比较。

原课程贡献：453→299 数据筛选。新代码、诊断、分组验证及价格偏离分析为课后个人扩展。

Source: Kaggle LLM Price-Performance Tracker, v1. Source metadata checked 2026-10-28. See README for provenance and licensing limits.